

basic statistics

주제

1. Iris 의 종별 Petal Length 평균 차이 검정
2. Iris 의 Petal Length 회귀 예측 모델 구축

1. 데이터 로드 및 구조 확인

- 코드 결과

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   sepal_length    150 non-null    float64
 1   sepal_width     150 non-null    float64
 2   petal_length    150 non-null    float64
 3   petal_width     150 non-null    float64
 4   species         150 non-null    object 
dtypes: float64(4), object(1)
memory usage: 6.0+ KB
```

2. 기술통계량


Species별 Petal Length의 평균, 개수, 표준편차, 최소/최대, 사분위수, 그룹별 데이터 개수

- 코드 결과

	count	mean	std	min	25%	50%	75%	max
species								
setosa	50.0	1.462	0.173664	1.0	1.4	1.50	1.575	1.9
versicolor	50.0	4.260	0.469911	3.0	4.0	4.35	4.600	5.1
virginica	50.0	5.552	0.551895	4.5	5.1	5.55	5.875	6.9

3. 시각화

- 코드 결과



- 해석

종 (species)에 따라 꽃잎 길이 (petal length)에 차이가 존재할 가능성을 시각적으로 확인할 수 있음.

세 종 간의 꽃잎의 길이의 분포가 잘 겹치지 않기 때문임.

각 종 별 꽃잎 길이의 분포를 보여줌.

setosa는 꽃잎 길이가 전반적으로 가장 짧고, 분산도 작은 편이며 이상치가 존재함.

versicolor는 setosa 보다 꽃잎 길이가 뚜렷하게 크며, 약한 이상치가 존재함.

virginica는 세 종 중 꽃잎 길이가 제일 긴 경향이 있음. 중앙값과 범위도 가장 큼.

4. 정규성 검정 (Shapiro-Wilk)

- 코드 결과

	species	W-statistic	p-value
0	setosa	0.954977	0.054811
1	versicolor	0.966004	0.158478
2	virginica	0.962186	0.109775

- 해석

Shapiro-Wilk 검정을 통해 species 별 petal_length의 정규성을 검정했음.

유의수준 0.05 하, 세 종 모두 p값이 0.05보다 커서, 귀무가설 (정규분포를 따름)을 기각하지 못함.

세 종 모두 정규성을 만족한다는 가정 하에 이하 분석을 진행함. (ANOVA 가정 만족)

5. 등분산성 검정 (Levene)

- 코드 결과

(np.float64(19.480338801923573), np.float64(3.1287566394085397e-08))

- statistic : 19.48...
- p-value = 3.13e-08

- 해석

species 별 petal_length의 등분산성을 검정함.

p-value = 3.13e-08 < 0.05 따라서 귀무가설 (세 그룹의 분산은 같음) 을 기각함.

세 종의 꽃잎 길이의 분산이 동일하지 않음.

하지만 과제 명세에 따라 등분산성을 만족한다는 가정 하에 이하 분석을 진행함.
(ANOVA 가정 만족)

6. ANOVA 가설 수립

- 가설 수립

귀무가설 (H_0) :

세 species (setosa, versicolor, virginica) 간 petal_length 평균은 모두 같음.

대립가설 (H_1):

적어도 한 species는 petal_length 의 평균이 다름.

7. One-way ANOVA

- 코드 결과

(np.float64(1180.1611822529785), np.float64(2.8567766109619814e-91))

- F statistic = 1180.16

- p-value = 거의 0

- 해석

귀무가설을 기각함. 세 종 간의 꽃잎 길이 차이가 통계적으로 유의미함.

8. 사후검정 (Tukey HSD)

- 코드 결과

Multiple Comparison of Means – Tukey HSD, FWER=0.05						
group1	group2	meandiff	p-adj	lower	upper	reject
setosa	versicolor	2.798	0.0	2.5942	3.0018	True
setosa	virginica	4.09	0.0	3.8862	4.2938	True
versicolor	virginica	1.292	0.0	1.0882	1.4958	True

- 결과 해석

one-way ANOVA 결과가 유의하여 Tukey HSD 사후검정을 실시함.

사후검정 결과, 모든 종 쌍에서 $p\text{-adj} < 0.05$ 이어서, petal_length 평균 차이가 통계적으로 유의미함.

또, meandiff 값을 보아, 꽃잎의 길이값은 setosa < versicolor < virginica 임을 알 수 있음.

9. 결과 요약

iris 데이터셋을 이용하여 종(species) 별 꽃잎 길이(petal_length) 평균 차이를 검정했음.

기술통계량과 박스플롯 시각화를 통해 species에 따라 petal_length 분포가 서로 다름을 시각적으로 확인함.

petal_length의 크기는

setosa < versicolor < virginica 순으로 증가하는 경향을 보임.

Shapiro-Wilk 검정 결과 세 종 모두 정규성을 만족하였으며,

Levene 검정 결과 등분산성은 만족하지 않았으나,

과제 명세에 따라 등분산성 만족한다는 가정 하에 이하 분석을 수행함.

One-way ANOVA 분석 결과,

세 종 간 petal_length 평균 차이는 통계적으로 유의미하였으며,

Tukey HSD 사후검정을 통해 모든 종 쌍 간 평균 차이가 유의함을 확인하였음.

10. 회귀분석

- 코드 결과

MSE: 0.13001626031382701
R^2: 0.9603293155857663
Intercept: -0.2621959025887084
feature coefficient
0 sepal_length 0.722815
1 sepal_width -0.635816
2 petal_width 1.467524

- 결과 해석

꽃잎 길이 (sepal_length) , 꽃받침 너비 (sepal_width), 꽃잎 너비 (petal_width) 를 독립변수로 하고, petal_length를 종속변수로 하는 선형 회귀분석을 수행함.

분석 결과, 예측오차 (MSE) 는 0.13 으로 비교적 작게 나왔으며,

R^{**2} 값은 0.96으로 독립변수들이 petal_length 변동의 약 96%를 설명함.

각 회귀계수 중에는, petal_length의 회귀계수가 가장 큰 값인 1.47 으로 가장 중요한 변수임을 알 수 있음.

또한 sepal_width의 회귀계수는 -0.64 으로, 증가할수록 petal_length가 감소하는 경향을 보임.